Predicción de incidencias operativas en vuelos programados desde BOS, JFK y LGA

Caso 05 · EYP3407 Tópicos Aplicados en Estadística

Diego Rodríguez · Eilenne Jaque · Benjamín Mondaca · Matías Gomez

Pontificia Universidad Católica de Chile · Profesor Eloy Alvarado Narváez · 12 de noviembre de 2026

Pregunta, población y respuesta

- **Pregunta:** ¿se puede identificar, con información de programación, qué vuelos terminarán cancelados, desviados o con ≥15 min de retraso de llegada?
- **Uso previsto:** analistas de operaciones que priorizan vuelos de mayor riesgo; no decide por sí solo.
- **Población:** vuelos domésticos desde BOS, JFK y LGA, 2022–2024; ≈10 % de los vuelos (regla determinista que no usa el resultado).
- **Unidad:** vuelo programado (fecha, aerolínea, número, origen, hora programada).
- **Respuesta:** Y = 1 si Cancelled = 1, Diverted = 1 o ArrDel15 = 1; Y = 0 en otro caso. Los indeterminados se reportan, no se recodifican (hay 0).
- **Alcance:** evaluación retrospectiva (prueba en 2024), sin validación en operación; supuesto de información; asociación, no causalidad.

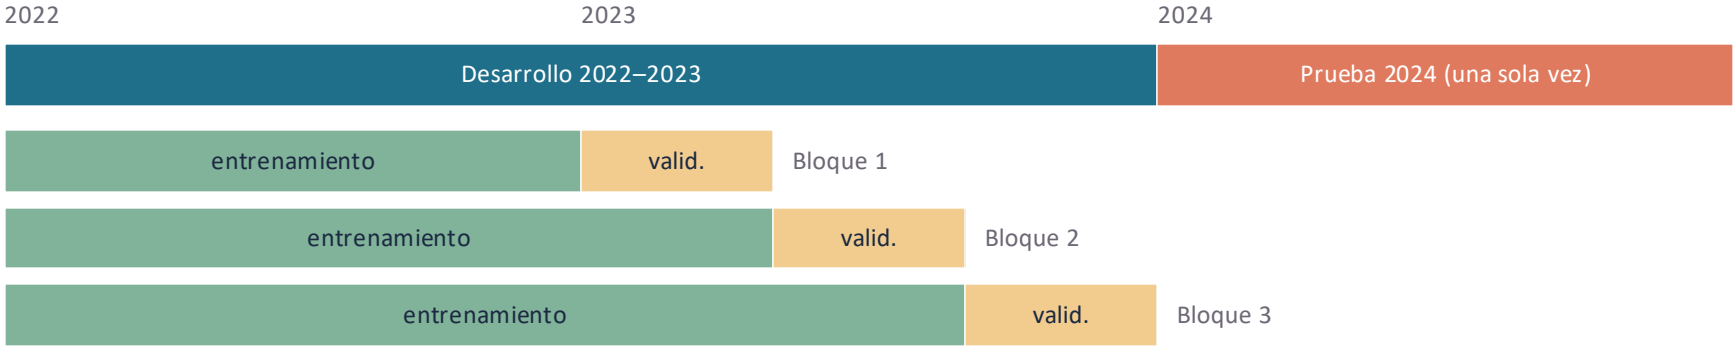
Datos y construcción de la muestra

Año	Vuelos	Incidencias	Prevalencia
2022	44 432	12 007	27,0 %
2023	43 496	10 009	23,0 %
2024	43 012	9 206	21,4 %
Total	130 940	31 222	23,8 %

Prevalencia en descenso: una constante entrenada en 2022–2023 (25,0 %) queda sobre la de 2024.

- **Fuente:** BTS, Reporting Carrier On-Time Performance; 36 archivos mensuales, 130 940 vuelos.
- **Calidad:** 0 claves duplicadas, 0 respuestas indeterminadas, 0 exclusiones.
- **Predictores:** programación, calendario y tasas históricas con solo días previos.
- **Excluidos:** tiempos reales, retrasos, causas, desvíos, códigos de cancelación y matrícula.

Diseño de validación e información admisible



- **Validación interna:** 3 bloques de 4 meses de 2023 (ene–abr, may–ago, sep–dic) con origen creciente; cada bloque incluye los 3 aeropuertos.
- **Información disponible:** programación y resultados de días anteriores (se conocen al cierre del día); sin brecha porque el horizonte es el propio vuelo.
- **Sin fuga:** preprocesamiento y tasas aprendidos solo con datos previos; 2024 no interviene en selección, hiperparámetros ni umbral.

Métricas, referencia y reglas fijadas antes de la prueba

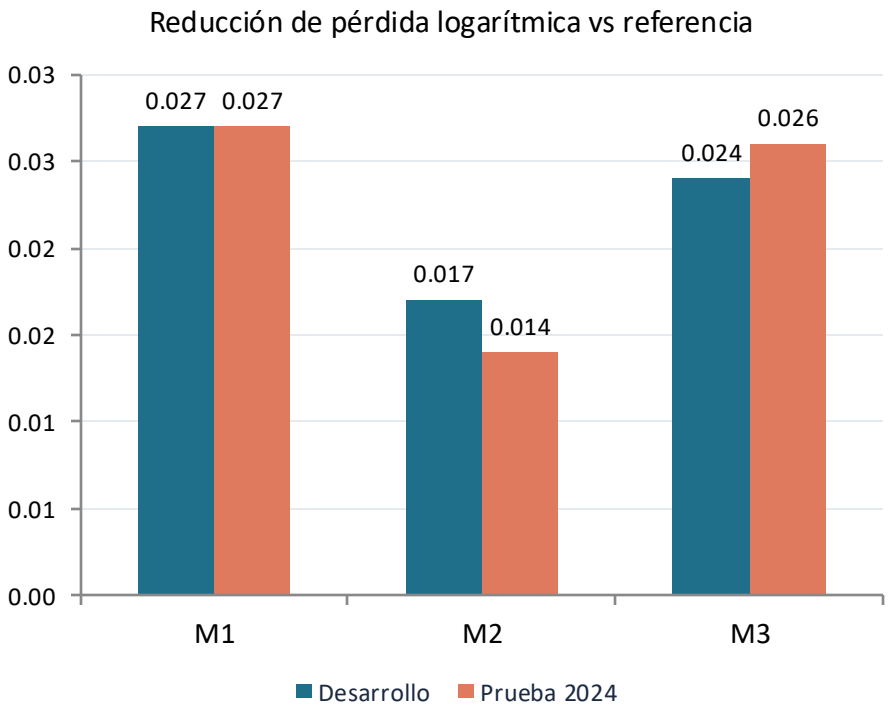
- **Métrica principal:** pérdida logarítmica (probabilidades acotadas a [0,001; 0,999]). Complementarias: Brier, AUC, calibración, sensibilidad y VPP.
- **Referencia:** probabilidad constante estimada solo con entrenamiento (25,0 % en desarrollo).
- **Selección:** menor pérdida media en los 3 bloques; ante diferencias pequeñas, el modelo más simple.
- **Umbral:** piso de sensibilidad ≥ 0,60 fijado a priori como requisito operativo supuesto (sin costos reales); el mayor umbral que lo cumple en validación es 0,24.
- **Prueba:** se evalúa una vez; no se cambian modelos, hiperparámetros ni umbral después.
- **Incertidumbre:** bootstrap por semanas completas (3 aeropuertos juntos), sin reajustar: condicional a los ajustes.

Métodos: tres procedimientos frente a una referencia

Modelo	Qué captura / cuándo falla	Hiperparámetros	Búsqueda
M1 Logística lasso/ridge (glmnet)	Efectos aditivos; no ve interacciones	$\alpha \in \{0, 1\}$; λ en 10 valores	20 config.
M2 Árbol podado (rpart)	Interacciones simples; probabilidades escalonadas, alta varianza	cp en 20 valores; minbucket = 50	20 config.
M3 Bosque aleatorio (ranger, 300 árboles)	No linealidades; puede sobreajustar y descalibrar	mtry; tamaño mínimo de nodo	20 + 12 + 4 (3 etapas)

- **Tasas históricas:** por ruta, aerolínea y origen×aerolínea, suavizadas (m = 20) con vuelos de días previos.
- **Selección de hiperparámetros:** pérdida media en los 3 bloques; M3 en 3 etapas porque el óptimo quedó en el borde de la grilla.
- **Preprocesamiento:** categorías con <30 vuelos y nuevas → «Otra»; faltantes → media de entrenamiento.

Resultados: M1 mejora a la referencia y M3 lo iguala

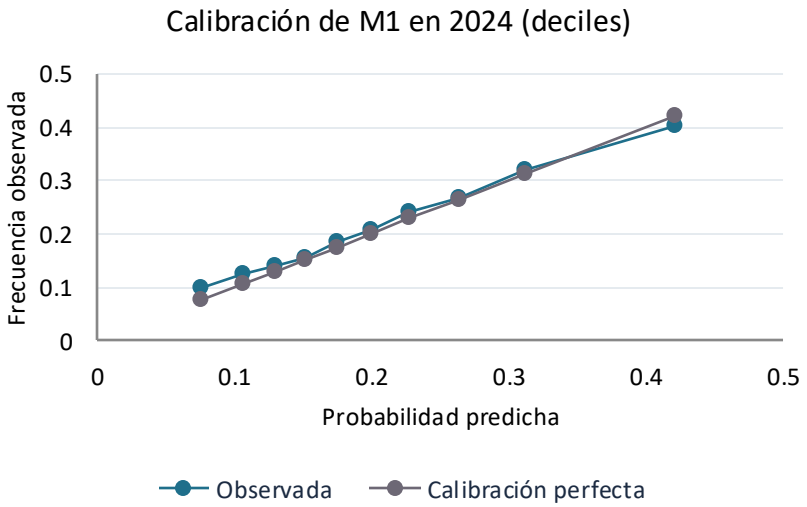


- **Prueba (n = 43 012):** pérdida referencia 0,523; M1 0,496; M3 0,497; M2 0,509. AUC de M1: 0,651.
- **M1 − referencia:** −0,0266 (percentil 95 %: −0,0340 a −0,0183).
- **M1 − M3:** −0,0007 (−0,0049 a +0,0035): empate; M1 ya estaba elegido en desarrollo por la regla.
- **Desarrollo:** M1 supera a la referencia en los 3 bloques; frente a M3, en 2 de 3.

Diagnóstico: heterogeneidad por temporada y calibración

Temporada	Prev.	Δ vs ref.	Sens.	VPP
Invierno	21,8 %	−0,005	0,403	0,293
Primavera	20,1 %	−0,021	0,417	0,295
Verano	30,4 %	−0,030	0,636	0,406
Otoño	13,3 %	−0,049	0,309	0,217

Δ = pérdida de M1 menos la de la referencia (negativo: mejor). Umbral 0,24; sensibilidad y VPP por temporada en 2024.



- **Umbral 0,24 en 2024:** marca 31,3 % de los vuelos; sensibilidad 0,478 (bajo el piso de 0,60) y VPP 0,326: con menor prevalencia, menos vuelos superan un umbral fijo.
- **Calibración:** media predicha 0,207 vs 0,214 observada; no hay desajuste de nivel.
- **Otros:** aeropuertos homogéneos (Δ −0,025 a −0,028); desviados: 106 casos, sensibilidad 0,321, imprecisa.

Sensibilidades (definidas con datos de desarrollo)

1 · Sin tasas históricas ni conteos

- Pérdida M1: 0,515 → 0,518 (+0,0037); M3: 0,518 → 0,522 (+0,0038); peor en los 3 bloques.
- M1 conserva ≈ 86 % de su ganancia sobre la referencia.
- M1 sigue siendo mejor que M3.
- Conclusión: la señal está sobre todo en programación y calendario; la historia aporta poco, pero de forma consistente.

2 · Rutas no vistas (20 %, 49 de 246)

- Rutas reservadas al azar, fuera del entrenamiento; arranque en frío (sin historia de ruta).
- Δ vs referencia: −0,0278 en rutas no vistas (7 265 vuelos) y −0,0252 en vistas (36 231).
- Conclusión: la mejora no depende de conocer la ruta.
- Límite: no prueba generalización a aeropuertos o destinos nuevos.

Recomendación, límites y reproducibilidad

Recomendación

- Usar M1 para priorizar vuelos, no para decidir.
- Umbral 0,24: marca 31 %, detecta 48 %, VPP 0,33 (1,5× la prevalencia).
- Reajustar el umbral con datos recientes.
- No usarlo para priorizar en invierno ni otoño.

Límites

- Evaluación retrospectiva; ≈10 % de los vuelos; 3 aeropuertos.
- Invierno: casi sin mejora (−0,005).
- Otoño: sensibilidad 0,31.
- Desviados: 106 casos.

Reproducibilidad

- Comando único: Rscript --vanilla main.R.
- Semilla 2026; R 4.6.0; glmnet, rpart, ranger.
- Resultados y sessionInfo en resultados/.
- Corrida limpia (10-11-2026): main.R sin errores, 84,2 min.

Apoyo · Variables admisibles y excluidas

Grupo	Variables	Decisión
Programación y calendario	Origin, Dest, DestState, Reporting_Airline, Distance, CRSElapsedTime, CRSDepTime/CRSArrTime (min), Month, DayOfWeek	Incluidas
Historia	Tasas por ruta, aerolínea y origen×aerolínea; conteos nprev_*	Incluidas (solo días previos)
Redundantes	Códigos DOT/IATA, IDs, ciudad, estado (salvo DestState) y WAC; Quarter, Flights, DistanceGroup, bloques horarios; número de vuelo	Excluidas
Posteriores a la salida	Tiempos reales, retraso de salida, causas, cancelación, campos Div*	Excluidas
Definen la respuesta	Cancelled, Diverted, ArrDel15, ArrDelay y derivadas	Excluidas
No acreditada	Tail_Number	Excluida

Apoyo · Búsqueda de hiperparámetros

Familia (etapa)	Mejor configuración	Pérdida media	Comentario
M1	$\alpha = 1$ (lasso), $\lambda = 10^{-4}$	0,515	20 configuraciones equivalentes
M2	cp = 0,0023	0,525	meseta para cp de 9×10^{-4} a $3{,}2\times10^{-3}$
M3 (etapa 1)	mtry = 3, nodo 200	0,546	óptimo en el borde de la grilla
M3 (etapa 2)	mtry = 5, nodo 2000	0,521	óptimo en el borde del tamaño de nodo
M3 (etapa 3)	mtry = 5, nodo 8000	0,518	meseta 0,518–0,520; última etapa

Apoyo · Desarrollo por bloque y umbral

Bloque	Ref.	M1	M2	M3	M1−Ref.	M1−M3	M1−M2
1 (ene–abr)	0,560	0,548	0,546	0,547	−0,0118	+0,0005	+0,0020
2 (may–ago)	0,568	0,533	0,547	0,540	−0,0355	−0,0069	−0,0146
3 (sep–dic)	0,497	0,463	0,481	0,467	−0,0332	−0,0034	−0,0174

Umbral 0,24	VP	FP	FN	VN	Sens.	VPP	Marcados
Bloque 1	2 293	5 238	1 340	5 892	0,631	0,304	51,0 %
Bloque 2	2 581	4 644	1 213	6 421	0,680	0,357	48,6 %
Bloque 3	1 272	3 172	1 310	8 120	0,493	0,286	32,0 %
Prueba 2024	4 398	9 080	4 808	24 726	0,478	0,326	31,3 %

Apoyo · Tasas históricas y supuestos

$$\tau_g(t) = \frac{S_g(t) + m\,\bar{y}(t)}{N_g(t) + m}, \quad m = 20 \qquad \bar{y}(t) = \frac{\sum_{s<t} S(s)}{\sum_{s<t} N(s)}$$

- $N_g(t)$, $S_g(t)$: vuelos e incidencias del grupo g en días estrictamente anteriores a t; $\bar{y}(t)$: tasa global acumulada hasta $t - 1$.
- **Interpretación:** promedio ponderado entre la tasa propia del grupo y la global. Con pocos vuelos previos (N_g pequeño) la tasa se acerca a $\bar{y}$; con muchos, a S_g / N_g. El valor $m = 20$ pesa como 20 vuelos de la tasa global.
- Grupos: ruta, aerolínea y origen×aerolínea; $N_g(t)$ entra como conteo nprev_*.
- Supuesto: el resultado de cada vuelo se conoce al cierre de su día; en 2024 la historia usa días previos de 2024.
- Primer día sin historia: la tasa se imputa con la media de entrenamiento.
- Los conteos nprev_* crecen con el calendario y pueden salir del rango de entrenamiento en 2024 (limitación).

Apoyo · Aeropuertos y tipos de incidencia (prueba 2024)

Aeropuerto	Vuelos	Prev.	Pérd. M1	Pérd. ref.	Δ	Sens.	VPP
BOS	14 514	21,8 %	0,502	0,528	−0,0259	0,481	0,341
JFK	12 244	22,4 %	0,509	0,534	−0,0250	0,513	0,331
LGA	16 254	20,3 %	0,482	0,510	−0,0284	0,445	0,309

Tipo de incidencia	Vuelos	Fracción marcada
Cancelado	845	0,507
Desviado	106	0,321
Retraso de llegada ≥ 15 min	8 255	0,477
Sin incidencia (falsas alarmas)	33 806	0,269